
PORTAFOLIO ACTUARIAL

Proyecto 03 • Python + GLM

Modelo GLM para Tarifación de Seguros de Gastos Médicos

*Distribución Tweedie • Relatividades de Riesgo • Validación
Cruzada*

Área: Pricing No-Vida • Ciencia de Datos Actuarial

Herramientas: Python 3 • statsmodels • scikit-learn

Modelo: GLM Tweedie (familia exponencial)

Ramo: Seguro de Gastos Médicos Mayores

Índice

1	Introducción al Proyecto	3
2	Marco Teórico	4
2.1	Modelos Lineales Generalizados (GLM)	4
2.2	Familia Exponencial de Distribuciones	4
2.3	La Distribución Tweedie	5
2.3.1	Función de varianza	5
2.3.2	Elección del parámetro p	5
2.3.3	Función de liga logarítmica	6
2.4	Relatividades de Riesgo	7
2.4.1	Intervalo de confianza de las relatividades	7
2.5	Devianza y Bondad de Ajuste	8
2.6	Estimación por Máxima Verosimilitud (MLE)	8
3	Descripción del Dataset	10
4	Pipeline del Modelo	11
4.1	Análisis Exploratorio (EDA)	11
4.1.1	Transformación logarítmica de la variable objetivo	11
4.2	Feature Engineering	11
4.2.1	Codificación categórica con <code>Treatment()</code>	12
4.3	Especificación del Modelo	13
4.3.1	El offset y su rol actuarial	14
4.4	Implementación en Python	14
4.5	Validación Cruzada	15
4.5.1	Pipeline de procesamiento	15
4.5.2	Scorer con función personalizada	15
4.5.3	Estrategia 5-fold	16
5	Interpretación de Resultados	17
5.1	Tabla de Relatividades	17
5.2	Interpretación Actuarial	17
6	Referencias	19

1. Introducción al Proyecto

Este proyecto construye un pipeline completo de tarificación actuarial para un seguro de gastos médicos mayores utilizando **Modelos Lineales Generalizados** (GLM) con distribución Tweedie. El objetivo es estimar la prima pura de cada asegurado en función de sus características individuales de riesgo, produciendo *relatividades* que el actuario de pricing puede incorporar directamente a la tarifa comercial.

El GLM Tweedie es el estándar de la industria aseguradora no-vida porque modela simultáneamente la probabilidad de siniestro (frecuencia) y el costo esperado (severidad) en una sola expresión, sin necesidad de modelar ambos componentes por separado.

2. Marco Teórico

2.1 Modelos Lineales Generalizados (GLM)

Un **Modelo Lineal Generalizado** (GLM) extiende la regresión lineal clásica a distribuciones que no son necesariamente normales. Un GLM se define por tres componentes:

1. **Componente aleatoria:** la variable respuesta Y pertenece a la familia exponencial de distribuciones.
2. **Predictor lineal:** combinación lineal de las variables explicativas:

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta}$$

3. **Función de liga g :** conecta la media de Y con el predictor lineal:

$$g(\mu_i) = \eta_i \quad \Longleftrightarrow \quad \mu_i = g^{-1}(\eta_i)$$

2.2 Familia Exponencial de Distribuciones

Una distribución pertenece a la **familia exponencial** si su función de densidad puede escribirse en la forma:

$$f(y; \theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}$$

La media y la varianza satisfacen:

$$\mathbb{E}[Y] = \mu = b'(\theta) \quad \text{Var}[Y] = a(\phi) \cdot b''(\theta) = a(\phi) \cdot V(\mu)$$

La función $V(\mu)$ se denomina **función de varianza** y caracteriza a la distribución dentro de la familia.

Distribución	$V(\mu)$	Parámetro p	Uso típico
Normal	1	$p = 0$	Modelos lineales clásicos
Poisson	μ	$p = 1$	Frecuencia de siniestros
Gamma	μ^2	$p = 2$	Severidad de siniestros
Tweedie	μ^p	$1 < p < 2$	Prima pura
Inversa Gaussiana	μ^3	$p = 3$	Tiempos de espera

2.3 La Distribución Tweedie

La **distribución Tweedie** con parámetro $p \in (1, 2)$ es una distribución compuesta Poisson-Gamma que tiene la propiedad de asignar probabilidad positiva a la masa en cero (probabilidad de no tener siniestros) y una distribución continua y asimétrica para valores positivos.

$$Y \stackrel{d}{=} \sum_{j=1}^N X_j \quad \text{donde} \quad N \sim \text{Poisson}(\lambda) \quad \text{y} \quad X_j \sim \text{Gamma}(\alpha, \beta)$$

Esto significa que Y es la suma de un número aleatorio N de siniestros, cada uno con un costo X_j distribuido Gamma. Es exactamente el modelo de riesgo colectivo aplicado a nivel individual, lo que hace a la Tweedie *el modelo natural para la prima pura*.

2.3.1 Función de varianza

$$\text{Var}[Y] = \phi \cdot \mu^p \quad p \in (1, 2)$$

El parámetro p (*power parameter*) controla cómo crece la varianza con la media. Valores cercanos a 1 se comportan más como Poisson (dominados por frecuencia); valores cercanos a 2 se comportan más como Gamma (dominados por severidad). En la práctica, p se estima a partir de los datos.

2.3.2 Elección del parámetro p

En este modelo se fija $p = 1.5$ por tres razones:

1. **Punto medio del rango actuarial.** $p = 1.5$ equidista entre la distribución Poisson

($p = 1$, dominada por frecuencia) y la Gamma ($p = 2$, dominada por severidad), representando un balance simétrico entre ambos componentes del riesgo.

2. **Convención empírica.** Estudios actuariales en seguros de gastos médicos reportan valores estimados de p entre 1.4 y 1.6, rango en el que la distribución captura adecuadamente la masa en cero y la asimetría de los siniestros individuales (Ohlsson & Johansson, 2010).
3. **Consistencia con el proceso generador.** El dataset sintético fue construido simulando una compuesta Poisson-Gamma con $p = 1.5$, lo que permite verificar que el modelo recupera correctamente el parámetro verdadero — una validación de especificación que no es posible con datos reales.

2.3.3 Función de liga logarítmica

La función de liga es la pieza que conecta el predictor lineal (que puede tomar cualquier valor entre $-\infty$ y $+\infty$) con la media de la respuesta (que en seguros debe ser positiva). Para la distribución Tweedie en pricing actuarial se usa la **liga logarítmica**:

$$g(\mu_i) = \ln(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta} \quad \implies \quad \mu_i = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$$

La función inversa es la exponencial, lo cual garantiza dos propiedades fundamentales para el pricing.

Primero, la exponencial de cualquier número es siempre positiva, por lo que la prima predicha nunca puede ser negativa, sin importar qué valores tomen los coeficientes o las variables explicativas.

Segundo — y ésta es la propiedad más importante para el pricing — la liga log convierte el modelo aditivo en un modelo *multiplicativo*. Por las propiedades de la exponencial, una suma en el exponente se transforma en un producto:

$$\mu_i = e^{\beta_0} \cdot e^{\beta_1 x_{1i}} \cdot e^{\beta_2 x_{2i}} \dots e^{\beta_p x_{pi}}$$

Cada variable **multiplica** la prima base en lugar de sumarle una cantidad fija, exactamente la estructura de relatividades que el equipo de pricing necesita. Esta es la diferencia fundamental con un modelo aditivo (liga identidad):

Tipo de modelo	Efecto del factor fumador
Aditivo (liga identidad)	+\$500 a la prima, sin importar el nivel base
Multiplicativo (liga log)	+43 % sobre la prima base, proporcionalmente

El multiplicativo refleja mejor la realidad biológica del riesgo: los factores no actúan independientemente, sino que se componen entre sí — una persona mayor que además fuma tiene un riesgo mucho mayor que la suma de los dos efectos por separado.

2.4 Relatividades de Riesgo

Una de las principales salidas del GLM en pricing es el cálculo de **relatividades**: factores que indican cuánto más (o menos) cuesta un seguro para un perfil de riesgo respecto a la categoría base.

Con la liga logarítmica, los coeficientes β_k se interpretan como:

$$\text{Relatividad}_k = e^{\beta_k}$$

Por ejemplo, si $\beta_{\text{fumador}} = 0.355$, la relatividad es $e^{0.355} \approx 1.427$, lo que significa que un asegurado fumador tiene un costo esperado 43 % mayor que un no fumador, manteniendo lo demás constante.

2.4.1 Intervalo de confianza de las relatividades

Cuando el GLM estima un coeficiente $\hat{\beta}$, ese valor es solo una estimación puntual basada en una muestra de datos. Si se recolectara otra muestra de pólizas, se obtendría un valor ligeramente distinto. El **intervalo de confianza (IC)** cuantifica esa incertidumbre: es el rango dentro del cual se encuentra el verdadero valor del parámetro con cierto nivel de confianza, convencionalmente 95 %.

$$\text{IC}_{95\%}(\beta_k) = \left[\hat{\beta}_k - 1.96 \cdot \text{SE}(\hat{\beta}_k), \hat{\beta}_k + 1.96 \cdot \text{SE}(\hat{\beta}_k) \right]$$

Para obtener el intervalo en escala de relatividades se aplica la exponencial a los límites del intervalo del coeficiente:

$$\text{IC}_{95\%}(\text{Relatividad}_k) = \left[e^{\hat{\beta}_k - 1.96 \cdot \text{SE}}, e^{\hat{\beta}_k + 1.96 \cdot \text{SE}} \right]$$

El intervalo de confianza permite dos lecturas críticas para el pricing:

- **Significancia estadística.** Si el intervalo de una relatividad contiene el valor 1, el factor podría no tener efecto real — su efecto no es distinguible estadísticamente de “ningún efecto”. Un actuario no aplicaría con confianza una relatividad cuyo intervalo cruza el 1.
- **Precisión de la estimación.** Un intervalo angosto indica que el factor está bien estimado. Un intervalo ancho indica mucha incertidumbre, generalmente por pocos datos en esa categoría — situación que se presenta a menudo en categorías con baja exposición.

2.5 Devianza y Bondad de Ajuste

La **devianza** es la métrica de bondad de ajuste para GLMs, análoga a la suma de cuadrados residuales en regresión lineal. Se define como:

$$D = 2 \left[\ell(\hat{\mu}_{\text{sat}}) - \ell(\hat{\mu}) \right]$$

donde $\ell(\hat{\mu}_{\text{sat}})$ es la log-verosimilitud del modelo saturado (un parámetro por observación) y $\ell(\hat{\mu})$ es la del modelo ajustado. La **devianza nula** compara contra el modelo con solo intercepto.

La **devianza explicada** (análoga a R^2) mide la proporción de variabilidad explicada por el modelo:

$$D^2 = 1 - \frac{D}{D_{\text{nula}}}$$

2.6 Estimación por Máxima Verosimilitud (MLE)

Los parámetros β se estiman maximizando la log-verosimilitud ponderada:

$$\hat{\beta} = \arg \max_{\beta} \sum_{i=1}^n w_i \cdot \ell(y_i; \mu_i(\beta), \phi)$$

donde w_i es el peso de cada observación (en seguros, habitualmente la exposición en años-póliza). El algoritmo utilizado es **IRWLS** (Iteratively Reweighted Least Squares), que converge a la solución de máxima verosimilitud mediante una secuencia de regresiones

lineales ponderadas.

3. Descripción del Dataset

El dataset sintético simula una cartera de **10,000 pólizas** de seguro de gastos médicos mayores del mercado mexicano. Las variables explicativas fueron elegidas por su relevancia actuarial documentada:

Variable	Tipo	Descripción actuarial
edad	Numérica	Principal predictor de mortalidad y morbilidad
sexo	Categórica	Diferencial de costo por género
imc	Numérica	Índice de masa corporal — proxy de salud
fumador	Binaria	Mayor riesgo cardíovascular y oncológico
region	Categórica	Diferencial de costos hospitalarios por zona
num_dependiente	Numérica	Número de beneficiarios adicionales
tipo_plan	Categórica	Individual / Familiar / Colectivo
deducible	Categórica	Alto / Medio / Bajo — afecta uso del seguro
exposicion	Numérica	Años-póliza de vigencia (offset del modelo)
prima_pura	Numérica	Variable objetivo — siniestros / exposición

4. Pipeline del Modelo

4.1 Análisis Exploratorio (EDA)

Antes de ajustar el modelo se verifica la distribución de la variable objetivo y su relación con cada predictor. Los puntos clave del EDA son:

- **Masa en cero:** proporción de pólizas sin siniestros — confirma que la Tweedie es apropiada.
- **Asimetría positiva:** la distribución de prima pura tiene cola derecha pesada — descarta la distribución normal.
- **Relación edad-costo:** curva exponencial creciente — sugiere transformación logarítmica o grupos de edad.
- **Efecto fumador:** diferencial significativo en la distribución de costos — variable de alta importancia predictiva.

4.1.1 Transformación logarítmica de la variable objetivo

Para visualizar la estructura de los datos cuando la variable tiene cola pesada y asimetría positiva, se aplica la transformación logarítmica:

$$y' = \ln(y + 1)$$

Esta transformación cumple tres propósitos en el análisis exploratorio:

- **Estabiliza la distribución**, haciéndola más simétrica y aproximadamente normal cuando los datos originales son lognormales.
- **Magnifica visualmente los valores pequeños** y reduce el peso visual de los valores extremos, permitiendo ver patrones que de otra forma quedarían escondidos en una distribución dominada por la cola derecha.
- Se suma 1 al argumento del logaritmo para **evitar** $\ln(0)$, que no está definido. Esto permite incluir los valores cercanos a cero sin que la transformación falle.

***Nota:** La transformación log es exclusiva para visualización. El GLM Tweedie modela directamente y sin transformar, ya que la liga log se aplica internamente en la estructura del modelo.*

4.2 Feature Engineering

Antes de ajustar el modelo se transforman las variables para capturar efectos no lineales y prepararlas para el GLM:

- **Grupos de edad:** la edad se discretiza en bandas quinquenales para capturar efectos no lineales sin sobreajuste.
- **Grupo de IMC:** se categorizan en Bajo peso / Normal / Sobrepeso / Obesidad siguiendo los criterios de la OMS.
- **Codificación:** variables categóricas codificadas con *dummy encoding* (una categoría base eliminada por variable).
- **Offset:** la exposición en años-póliza se incluye como offset logarítmico $\ln(e_i)$ para normalizar por tiempo de vigencia.

4.2.1 Codificación categórica con `Treatment()`

Un GLM solo puede operar con números, no con texto. Cuando una variable es categórica con k niveles, debe convertirse en $k - 1$ variables indicadoras (dummies); una de las categorías se omite y se convierte en la **categoría de referencia**, que queda absorbida en el intercepto. Si se usaran las k dummies completas se tendría colinealidad perfecta — la trampa de la variable dummy — y el modelo no podría estimarse.

En statsmodels, la sintaxis para esta codificación viene de la librería Patsy:

- `C(variable)` marca la columna como categórica y aplica codificación dummy. Por defecto, Patsy elige como referencia la categoría que aparece primero alfabéticamente.
- `Treatment("X")` sobrescribe ese comportamiento: especifica explícitamente que X sea la categoría de referencia.

La elección de la referencia no es cosmética: determina contra qué se comparan todas las relatividades. Por eso en el modelo se eligieron referencias con sentido de negocio:

Variable	Referencia	Justificación
grupo_imc	Normal	El IMC saludable es el punto de comparación natural
fumador	No	El no fumador es el perfil de menor riesgo base
deducible	Medio	El nivel intermedio como punto neutro
grupo_edad	36-45	Edad media, ni la más joven ni la más vieja
region	Centro	Región de riesgo promedio
sexo	F	Convención (cualquiera sirve como base)

Si se dejara que Patsy eligiera la referencia alfabéticamente, en **deducible** la base sería “Alto” (primero alfabéticamente), lo cual no tiene sentido como punto de comparación neutro y produciría relatividades mayores a 1 para “Medio” y “Bajo” — contraintuitivo de leer. Al fijar “Medio” como base, el deducible alto reduce la prima (relatividad < 1 , efecto del riesgo moral) y el bajo la aumenta (relatividad > 1).

4.3 Especificación del Modelo

El modelo ajustado es:

$$\ln\left(\frac{\mu_i}{e_i}\right) = \beta_0 + \beta_{\text{edad}}x_{\text{edad},i} + \beta_{\text{sexo}}x_{\text{sexo},i} + \beta_{\text{imc}}x_{\text{imc},i} + \beta_{\text{fum}}x_{\text{fum},i} + \dots$$

equivalentemente:

$$\mu_i = e_i \cdot \exp\left(\beta_0 + \sum_{k=1}^p \beta_k x_{ki}\right) = e_i \cdot \lambda_{\text{base}} \cdot \prod_{k=1}^p r_k^{x_{ki}}$$

donde $r_k = e^{\beta_k}$ es la relatividad del factor k y $\lambda_{\text{base}} = e^{\beta_0}$ es la prima pura de la categoría base.

4.3.1 El offset y su rol actuarial

Las pólizas no tienen todas la misma duración — algunas son anuales, otras semestrales, otras parciales. Si no se ajusta por esta diferencia, una póliza de 6 meses con un siniestro parecería tener la misma frecuencia que una póliza de 12 meses con un siniestro, cuando en realidad la primera tiene el doble de frecuencia anualizada.

El **offset** es el mecanismo del GLM para ajustar por esta diferencia. Al incluir $\ln(e_i)$ como un término del predictor lineal con coeficiente fijo igual a 1 (es decir, no se estima), el modelo predice directamente la prima pura anualizada:

$$\ln(\mu_i) = \ln(e_i) + \beta_0 + \beta_1 x_{1i} + \dots \quad \Rightarrow \quad \mu_i = e_i \cdot \exp\left(\beta_0 + \sum_k \beta_k x_{ki}\right)$$

La prima esperada μ_i queda automáticamente escalada por la exposición real de cada póliza. Esto convierte el modelo en un análisis de riesgo *por unidad de tiempo*, no de monto total observado.

4.4 Implementación en Python

La implementación con `statsmodels` es directa una vez configuradas la familia y la fórmula:

```
import statsmodels.api as sm
import statsmodels.formula.api as smf

# Familia Tweedie con liga log y power=1.5
familia = sm.families.Tweedie(
    var_power=1.5,
    link=sm.families.links.Log()
)

# Ajuste del modelo con exposicion como offset
modelo = smf.glm(
    formula="prima_pura ~ ...",
    data=df_train,
    family=familia,
    offset=np.log(df_train[.exposicion"])
).fit()
```

4.5 Validación Cruzada

El modelo se valida con **k-fold cross-validation** ($k = 5$) calculando la devianza Tweedie en cada fold. Esta sección detalla las tres piezas del proceso: el pipeline, el scorer y la estrategia de partición.

4.5.1 Pipeline de procesamiento

Un **pipeline** es una cadena de pasos de procesamiento que se ejecutan en orden, como una línea de ensamblaje. En lugar de aplicar manualmente cada transformación a los datos y luego ajustar el modelo, el pipeline encadena todo en un solo objeto:

```
pipeline = Pipeline([
    ('prep', preprocessor),          # Paso 1: transformar
    ('glm', TweedieRegressor(power=1.5, ...)) # Paso 2: ajustar
])
```

La razón crítica por la que el pipeline importa es la prevención del *data leakage*. Durante la validación cruzada, los datos se dividen en particiones, y el pipeline garantiza que la transformación (encoding) se ajuste *solo con los datos de entrenamiento* de cada partición y luego se aplique a los datos de prueba. Si se hiciera el encoding antes de dividir, se estaría filtrando información del conjunto de prueba hacia el entrenamiento — un error sutil que infla artificialmente el rendimiento.

4.5.2 Scorer con función personalizada

La métrica natural para un GLM Tweedie es la devianza Tweedie, que depende del parámetro `power`:

$$D_{\text{Tweedie}}(y, \hat{\mu}) = 2 \sum_{i=1}^n \left[\frac{y_i^{2-p}}{(1-p)(2-p)} - \frac{y_i \hat{\mu}_i^{1-p}}{1-p} + \frac{\hat{\mu}_i^{2-p}}{2-p} \right]$$

Esta métrica no puede pasarse como string directo a `cross_val_score` porque requiere especificar `power`. Por eso se construye un scorer personalizado con `make_scorer`:

```
tweedie_scorer = make_scorer(
    mean_tweedie_deviance,
    power=1.5,          # mismo power que el modelo
    greater_is_better=False # menor devianza = mejor
)
```

El parámetro `greater_is_better=False` es esencial: la devianza es una medida de

error (como la suma de cuadrados residuales), así que menos devianza significa mejor ajuste. Sin esta configuración, scikit-learn asumiría que más es mejor y elegiría el peor modelo.

4.5.3 Estrategia 5-fold

La validación cruzada *k-fold* evalúa qué tan bien generaliza el modelo a datos que no ha visto. El “5-fold” significa que se hace con 5 particiones:

1. El dataset se divide en **5 partes (folds) iguales**.
2. Se entrena el modelo 5 veces. En cada ronda, 4 partes se usan para entrenar y 1 para probar, rotando cuál es la de prueba.
3. Cada ronda produce una devianza. Al final se obtienen 5 valores que pueden promediarse.

Ronda	Entrenamiento	Prueba
1	Folds 2, 3, 4, 5	Fold 1
2	Folds 1, 3, 4, 5	Fold 2
3	Folds 1, 2, 4, 5	Fold 3
4	Folds 1, 2, 3, 5	Fold 4
5	Folds 1, 2, 3, 4	Fold 5

Los parámetros de configuración son:

- `n_splits=5` — equilibra robustez estadística y costo computacional.
- `shuffle=True` — mezcla los datos antes de dividir, evitando que algún orden oculto sesgue las particiones.
- `random_state=42` — fija la semilla para que la división sea reproducible.

Si las 5 devianzas son similares entre sí (baja desviación estándar), el modelo es estable y generaliza bien. Si varían mucho, el modelo es sensible a qué datos le tocaron — señal de sobreajuste o datos insuficientes en algún segmento. Por eso al final se reporta no solo la media sino también la desviación estándar y el coeficiente de variación.

5. Interpretación de Resultados

5.1 Tabla de Relatividades

La tabla de relatividades es el principal entregable del modelo para el equipo de pricing. Cada relatividad indica cuánto multiplica ese factor a la prima base, y va acompañada de su intervalo de confianza al 95 % para evaluar la confiabilidad de la estimación:

Variable	Categoría	$\hat{\beta}$	Relatividad
Sexo	Femenino (base)	0.000	1.000
	Masculino	0.233	1.262
Grupo IMC	Normal (base)	0.000	1.000
	Sobrepeso	0.484	1.622
	Obesidad	0.734	2.084
Fumador	No (base)	0.000	1.000
	Sí	0.355	1.427
	Medio (base)	0.000	1.000
	Bajo	0.304	1.355
	Alto	-0.236	0.790

5.2 Interpretación Actuarial

- **Fumador:** relatividad de 1.427 indica que un asegurado fumador tiene un costo esperado 43 % mayor que uno no fumador con el mismo perfil. Este diferencial es consistente con la literatura médica sobre costos asociados al tabaquismo.
- **Obesidad:** relatividad de 2.084 refleja el mayor uso de servicios médicos asociado a enfermedades crónicas como diabetes tipo 2, hipertensión y problemas cardiovasculares, frecuentes en población con obesidad.
- **Deducible alto:** relatividad de 0.790 captura el efecto del *riesgo moral* — asegurados con deducible alto tienen incentivo a usar el seguro solo para siniestros significativos, reduciendo el costo esperado.

- **Edad:** la curva de relatividades por grupo de edad es creciente y acelerada, consistente con el incremento exponencial de la mortalidad y morbilidad descrito por la ley de Gompertz-Makeham.

6. Referencias

- Ohlsson, E., & Johansson, B. (2010). *Non-Life Insurance Pricing with Generalized Linear Models*. Springer.
- Nelder, J. A., & Wedderburn, R. W. M. (1972). Generalized Linear Models. *Journal of the Royal Statistical Society*, 135(3), 370–384.
- Tweedie, M. C. K. (1984). An index which distinguishes between some important exponential families. *Statistics: Applications and New Directions*, 579–604.
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2nd ed.). Chapman & Hall.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.